

DeGro: Kiểm chứng tính xác định của đại lượng đích và sửa chữa có căn cứ cho suy luận toán học thực thi được

Bản dịch tiếng Việt để đọc và tham khảo

Tác giả ẩn danh

Dịch từ bản thảo tiếng Anh trong `paper/main.pdf`

15 tháng 9 năm 2026

Lưu ý về bản dịch. Đây là bản dịch phục vụ việc đọc, không phải bản công bố chính thức. Các ký hiệu toán học, tên mô hình, tên tập dữ liệu, số liệu, khóa trích dẫn và tên tài liệu tham khảo được giữ nguyên để đối chiếu với bản gốc.

Tóm tắt

Suy luận toán học thực thi được có thể chạy thành công nhưng vẫn đang giải một bài toán bị thiếu ràng buộc hoặc bị dịch sai sang biểu diễn hình thức. Các phép kiểm tra thực thi phát hiện lỗi cú pháp, lỗi thời gian chạy và lỗi số học, nhưng không chứng minh rằng các ràng buộc đã mã hóa đủ để xác định đại lượng đích được hỏi. Chúng tôi giới thiệu *DeGro*, một khung neuro-symbolic cho *chẩn đoán tính xác định của đại lượng đích*. DeGro yêu cầu bộ giải tìm hai phép gán khả thi nhưng cho hai giá trị đích khác nhau; nếu tồn tại, một chính sách có căn cứ chỉ thêm ràng buộc được nguồn hỗ trợ để khôi phục tính xác định, hoặc từ chối trả lời. Trong đánh giá ghép cặp được đăng ký trước, nơi biểu diễn hình thức được giữ cố định còn mức hỗ trợ từ đề bài thay đổi, DeGro cải thiện độ chính xác sửa-chữa-hoặc-từ-chối đối với GPT-OSS 20B nhưng không cải thiện với Gemma 4 31B. Các nghiên cứu lỗi tự nhiên do con người kiểm tra cho thấy DeGro tăng độ chính xác trên nhóm MATH-500 được hỗ trợ, trong khi ALG514 có độ phủ cao hơn làm lộ các lỗi hình thức hóa vẫn tương thích với đáp án. Phát hiện dễ hơn sửa chữa rất nhiều, và các phản ví dụ cụ thể không đem lại lợi ích đo được ngoài phán quyết của bộ giải. Vì vậy, tính xác định của đại lượng đích là một hàng rào trung gian có thể kiểm toán, chứ không phải bằng chứng rằng phép dịch từ đề bài sang biểu diễn hình thức là trung thành.

Từ khóa: suy luận neuro-symbolic; tác tử toán học; kiểm chứng; phản ví dụ; từ chối trả lời.

1 Giới thiệu

Các mô hình ngôn ngữ lớn ngày càng giao việc tính toán toán học cho chương trình và bộ giải ký hiệu. Suy luận có chương trình hỗ trợ làm giảm lỗi số học, còn các hệ thống như SymCode sinh chương trình ký hiệu khép kín và sửa lỗi thực thi [7, 21]. Tuy nhiên, chạy thành công là một chứng nhận yếu: nó chỉ cho thấy tạo phẩm có thể chạy, chứ không cho thấy tạo phẩm đã mã hóa đủ thông tin của đề bài để biện minh cho đáp án được yêu cầu.

Xét ví dụ: “Mười nhiệm vụ được chia cho A và B. A nhận nhiều hơn B hai nhiệm vụ. Hỏi A nhận bao nhiêu?” Một mô hình sinh ra chỉ chứa $a + b = 10$ vẫn thực thi được và khả thi, nhưng $(a, b) = (4, 6)$ và $(6, 4)$ cho hai giá trị khác nhau của đích a . Cũng chính mô hình đó lại trung thành với đề ngắn hơn: “Mười nhiệm vụ được chia cho A và B. Hỏi A nhận bao nhiêu?” Ở trường hợp đầu, $a = b + 2$ là một phép dịch còn thiếu; ở trường hợp sau, thêm phương trình ấy là bịa ra thông tin. Trạng thái bộ giải giống hệt nhau, nhưng hành động đúng thay đổi theo mức hỗ trợ của nguồn.

Thành công khi thực thi, sự trùng khớp đáp án và một điểm tin cậy vô hướng đều không cho biết miền nghiệm khả thi có xác định duy nhất đại lượng đích hay không, cũng không cho biết đề bài có cho phép một sửa chữa được đề xuất hay không. Vì vậy, một tác tử diễn đạt trôi chảy vẫn có thể báo một giá trị duy nhất trong khi mô hình của nó cho phép nhiều giá trị.

Chúng tôi đề xuất **DeGro**, một khung neuro-symbolic xem thất bại này như một bài toán chẩn đoán có cấu trúc. Khung tạo hai bản sao đổi tên của đặc tả đã sinh và hỏi liệu cả hai có thể đồng thời thỏa các ràng buộc nhưng bất đồng về đại lượng đích hay không. Nếu truy vấn khả thỏa, ta nhận được bằng chứng có thể kiểm toán về sự mơ hồ. Sau đó, DeGro phân tách hai nguyên nhân của sự mơ hồ bằng cổng sửa-chữa-hoặc-từ-chối có căn cứ từ nguồn: sửa một thiếu sót được đề bài hỗ trợ, hoặc từ chối bịa ra sự kiện còn thiếu.

Có thể xem đánh giá suy luận thực thi được ở ba tầng: (i) tầng thực thi hỏi chương trình có chạy không; (ii) tầng kết quả hỏi dự đoán đúng hay sai; và (iii) tầng tính xác định hỏi hai mô hình khả thi có thể cho hai giá trị đích khác nhau hay không, rồi chuyển sang sửa chữa có căn cứ hoặc từ chối. Hai tầng đầu trả về phán quyết thô; tầng thứ ba chẩn đoán cấu trúc của miền nghiệm trước khi tác tử cam kết một đáp án.

Các đóng góp của bài báo gồm: **(1)** một thuộc tính hướng đích, yếu hơn tính duy nhất của toàn bộ mô hình nhưng phù hợp với điều một tác tử trả lời cần biện minh; **(2)** một chẩn đoán hai bản sao cùng cổng tất định, chỉ chấp nhận sửa chữa có nguồn hỗ trợ, nhất quán, không dư thừa và khôi phục tính xác định; và **(3)** một đánh giá ghép cặp đăng ký trước, bổ sung bằng lỗi tự nhiên do con người kiểm tra, qua đó tách sửa chữa khỏi từ chối, cho thấy mức tăng phụ thuộc mô hình và khoảng cách giữa phát hiện với sửa chữa. Bài báo nghiên cứu độ chính xác quyết định (**RQ1**), phép bổ sung không được hỗ trợ (**RQ2**), ích lợi của cặp chứng kiến (**RQ3**), cùng độ phủ, khả năng phát hiện và sửa chữa trên lỗi tự nhiên (**RQ4**).

2 Công trình liên quan

Suy luận thực thi được và kiểm chứng học được

Chain-of-thought biểu lộ các bước suy luận trung gian [47]; PAL và Program-of-Thoughts giao việc tính toán cho chương trình được sinh ra [10, 21]. Toolformer và ReAct nghiên cứu việc dùng công cụ nói chung [40, 52]; MathCoder và ToRA chuyên biệt hóa các hành động thực thi cho toán học [25, 46]. Faithful chain-of-thought đưa thực thi ký hiệu vào chính phần lập luận [35]. SymCode coi chương trình ký hiệu là tạo phẩm suy luận trung tâm và sửa lỗi thời gian chạy [7]. Những hệ thống này cải thiện độ tin cậy tính toán, nhưng chạy thành công không đồng nghĩa với việc tạo phẩm chứa đủ ràng buộc để biện minh cho đích. DeGro xử lý lỗi hậu sinh bổ sung này: chương trình có thể phân tích cú pháp, chạy và trả về một giá trị trong khi miền nghiệm của nó vẫn cho phép nhiều đáp án.

Các bộ kiểm chứng kết quả xếp hạng đáp án ứng viên, còn giám sát quá trình đánh giá từng bước trung gian [14, 34, 44]. Self-verification, Self-Refine và CRITIC yêu cầu mô hình tự xem xét hoặc chỉnh sửa đầu ra [24, 36, 48]. Việc sửa lại có thể tăng độ chính xác đáp án, nhưng tự hiệu chỉnh nội tại không đáng tin nếu thiếu tín hiệu bên ngoài [27]. DeGro cung cấp một tín hiệu cơ học, riêng cho đại lượng đích, thay vì một điểm số hay lời phê bình tự do. Cặp chứng kiến bác bỏ tính xác định của biểu diễn; nó không chứng nhận rằng buộc thay thế nào là đúng.

Chẩn đoán quan hệ và sửa chữa

Self-composition quy một thuộc tính hai lần thực thi về truy vấn an toàn thông thường bằng cách ghép chương trình với bản sao đã đổi tên [8, 43]. Product programs và Cartesian Hoare logic

mô-đun hóa lập luận quan hệ [9, 42]; hyperproperties và HyperLTL mở rộng lập luận từ từng vết sang tập các vết [12, 13, 20]. DeGro dùng cùng ý tưởng hai bản sao cho một quan hệ khác: mọi phép gán khả thi phải đồng thuận về đại lượng toán học đích. Truy vấn này yếu hơn tính duy nhất của toàn trạng thái và phù hợp hơn với điều một tác tử trả lời phải thiết lập.

Các hệ ký hiệu gần đây chẩn đoán lỗi ngữ nghĩa mà thực thi thông thường bỏ sót. ReLoop gây nhiễu tham số để lộ mô hình tối ưu hóa sai dù vẫn chạy [32]. SymDiag kiểm tra tính khả thỏa và hệ quả ở từng bước rồi trả bằng chứng có cấu trúc [16]. Phương pháp dựa trên lỗi sửa biểu diễn quá ràng buộc bằng phân tích tập con bất khả thỏa tối thiểu [33, 39]. DeGro nằm ở chế độ thiếu ràng buộc: F khả thỏa, nhưng hai mô hình khả thi bất đồng về q . Phản chứng cơ học của nó có quan hệ với trừu tượng hóa và tổng hợp có phản ví dụ dẫn đường [11, 41], song chỉ thiết lập sự mơ hồ chứ không chỉ ra phép sửa đúng.

Căn cứ nguồn, từ chối và tính trung thành

Dự đoán chọn lọc hình thức hóa đánh đổi rủi ro—độ phủ khi có lựa chọn từ chối [15, 19, 22, 23]; learning-to-defer chuyển trường hợp khó cho một bên ra quyết định khác [37]; conformal risk control hiệu chỉnh các hành động được chọn [3]. Tự trị thức của mô hình ngôn ngữ và bất định ngữ nghĩa cung cấp tín hiệu tin cậy [30, 31]. DeGro hỏi một câu khác: ràng buộc đã mã hóa có cho phép nhiều giá trị đích về mặt logic hay không, và nguồn có cho phép thu hẹp miền đó không. Kết quả unknown của bộ giải là lỗi độ phủ, không phải bằng chứng mơ hồ. Một đích mơ hồ đòi hỏi sửa chữa, hỏi lại hoặc từ chối, ngay cả khi mô hình ngôn ngữ rất tự tin.

Chẩn đoán cổ điển xác định giả định lỗi, còn abduction tìm giả thuyết khôi phục thuộc tính mong muốn [18, 38]. Sửa mô hình dựa trên SAT thay đổi hệ chuyển trạng thái đến khi thỏa đặc tả [4]; các nghiên cứu dựa trên LLM sửa mô hình khai báo Alloy [2]. Phép chỉnh sửa hợp lệ của chúng tôi cố ý hẹp hơn: đề xuất phải trích nguồn, giữ tính nhất quán, bổ sung thông tin chưa được suy ra và khôi phục tính xác định của đích. Thiết kế này ngăn “sửa chữa” tầm thường bằng cách ghim đích vào một đáp án đoán.

Autoformalization và chứng minh định lý đang tạo ra các tạo phẩm hình thức ngày càng mạnh [6, 28, 29, 49–51]. Các benchmark như miniF2F, ProofNet, Lean Workbook và FormalMATH mở rộng nền đánh giá hình thức [5, 53–55]; tuy nhiên, được bộ chứng minh chấp nhận không đủ để chứng tỏ ý nghĩa của nguồn đã được bảo toàn. MIRA-Math nghiên cứu câu hỏi cần một sự kiện cần thiết bị ẩn [1]. Bài báo dùng các trạng thái ẩn đã kiểm định của nó để tạo cặp sửa chữa/từ chối tương ứng, đồng thời không cho mô hình sửa chữa thấy đáp án ẩn.

3 Phương pháp

DeGro gồm hai giai đoạn: trước hết chẩn đoán xem đặc tả sinh ra có xác định đại lượng đích hay không; sau đó chuyển một phán quyết mơ hồ thành sửa chữa có căn cứ từ nguồn hoặc từ chối có nguyên tắc.

3.1 Thiết lập bài toán, tính xác định và tính đúng đắn

Cho bài toán ngôn ngữ tự nhiên P . Một mô hình sinh $F = (V, D, C, q)$, trong đó V là các biến, D là miền của chúng, C là các ràng buộc, và $q(V)$ là biểu thức được hỏi. Đặt

$$\text{Sol}(F) = \{m \mid m \models D \wedge C\}.$$

Đích được gọi là *xác định dưới* F khi và chỉ khi

$$\forall m_1, m_2 \in \text{Sol}(F), \quad q(m_1) = q(m_2).$$

Đây là điều kiện yếu hơn nghiệm duy nhất: $x = 5, y \geq 0$ có nhiều mô hình, nhưng đích $q = x$ vẫn xác định.

Tạo hai bản sao đổi tên $F^{(1)}$ và $F^{(2)}$, rồi truy vấn

$$\Phi(F, q) = F^{(1)} \wedge F^{(2)} \wedge q(V^{(1)}) \neq q(V^{(2)}). \quad (1)$$

Nếu truy vấn (1) khả thỏa, hai mô hình chiếu ra tạo thành một *cặp chứng kiến phân kỳ đích*. Nếu truy vấn bất khả thỏa và bản thân F khả thỏa, đích là xác định.

Bảo đảm. Với bộ giải đúng và lý thuyết được hỗ trợ, $\text{SAT}(F)$ cùng kết quả unsat cho (1) suy ra mọi mô hình của F đồng thuận về q ; nếu có một cặp bất đồng, cặp đó sẽ thỏa truy vấn. Hết thời gian và unknown không chứng minh điều gì. Bảo đảm này phụ thuộc truy vấn và chỉ nói về F , không phải tương đương ngữ nghĩa $F \equiv P$: ràng buộc thừa hoặc sai có thể ép ra một đáp án duy nhất nhưng dịch sai. Ngược lại, luôn có thể tùy tiện tăng cường mô hình để ép tính xác định, nên cần thêm yêu cầu về căn cứ nguồn. Chính sách chỉ thêm ràng buộc vào đặc tả mơ hồ; xóa hoặc sửa một biểu diễn đã xác định nhưng sai nằm ngoài phạm vi.

Tính xác định của đích cố ý yếu hơn tính duy nhất của mô hình. Một mô hình lập lịch có thể dễ tự do nhiều phép gán nhưng cố định tổng chi phí; một bài toán lời văn có thể có nhiều giá trị cho biến phụ nhưng cố định đại lượng được hỏi. Bác bỏ các trường hợp này sẽ đánh đồng tự do biểu diễn với mơ hồ đáp án. Cặp chứng kiến cũng có thể kiểm tra độc lập bằng cách thế từng phép gán vào $D \wedge C$ và so sánh giá trị đích. Tính xác định đơn điệu theo phép tăng cường nhất quán, nhưng chiều ngược lại không an toàn vì một sự kiện tùy ý như $q = 6$ luôn có thể làm miền giá trị đích co lại.

Ví dụ xuyên suốt. Cho $V = \{a, b\}$ là các số nguyên không âm, $C = (a + b = 10)$ và $q = a$. Truy vấn nhân đôi có thể trả $(a_1, b_1) = (4, 6)$ và $(a_2, b_2) = (6, 4)$. Nếu P nói “A nhận nhiều hơn B hai nhiệm vụ”, thì $a = b + 2$ được hỗ trợ, nhất quán, không dư thừa và đủ để suy ra $a = 6$. Nếu không có câu ấy, phương trình trở thành giả định bịa đặt và hành động đúng là từ chối. Mô hình sửa chữa không thấy giá trị vàng ẩn cũng như ràng buộc vàng bị thiếu.

Biểu diễn có cấu trúc. Tác tử phát một ModelSpec có kiểu, gồm kiểu và cận của biến, các ràng buộc liên kết với nguồn, cùng đại lượng đích. Các trình biên dịch tắt định dịch nó sang backend tính toán và kiểm chứng, tránh sinh độc lập chương trình SymPy và SMT. Mảnh ngôn ngữ được hỗ trợ gồm biến nguyên, thực, Boolean; đẳng thức và bất đẳng thức số học; miền hữu hạn; và một số ràng buộc mô-đun. Cú pháp khác trả về not-supported.

3.2 Giai đoạn I: chẩn đoán tính xác định của đích

DeGro trước hết kiểm tra $\text{SAT}(F)$, trả inconsistent hoặc unknown khi thích hợp, rồi mới đánh giá (1). Bất khả thỏa cho phép trả lời trong phạm vi F ; khả thỏa trả hai phép gán có giá trị đích khác nhau và kích hoạt sửa chữa. Giai đoạn này tắt định: mô hình đề xuất F nhưng không tự phán xét tính xác định.

Thuật toán 1: Kiểm chứng tính xác định của đích

1. Tính $r_0 \leftarrow \text{CheckSat}(D \wedge C)$.
2. Nếu $r_0 = \text{unsat}$, trả inconsistent; nếu $r_0 \neq \text{sat}$, trả unknown.
3. Tạo $\Phi \leftarrow F^{(1)} \wedge F^{(2)} \wedge (q^{(1)} \neq q^{(2)})$ bằng hai bản sao rời nhau.
4. Tính $(r_1, M) \leftarrow \text{CheckSat}(\Phi)$.
5. Nếu $r_1 = \text{unsat}$, trả determinate; nếu $r_1 \neq \text{sat}$, trả unknown.
6. Trả ambiguous cùng hai chứng kiến chiếu từ M .

Bản ghi lưu cả hai phán quyết của bộ giải, giá trị đích đã chuẩn hóa và chứng kiến đầy đủ khi có. Chỉ ambiguous mới cho phép sửa chữa; lý thuyết không được hỗ trợ và hết thời gian không bao giờ bị ép thành kết quả Boolean.

3.3 Giai đoạn II: sửa chữa có căn cứ hoặc từ chối

Mô hình sửa chữa nhận P, C, q cùng cặp chứng kiến, rồi trả add-constraint kèm đoạn nguồn chính xác hoặc abstain. Ứng viên phải biên dịch được, trích văn bản trong P (hoặc một quy tắc miền đã khai báo), giữ tính khả thỏa, không dư thừa và khôi phục tính xác định. DeGro dùng tối đa hai vòng; nếu không thành công, trả underspecified. Nguồn gốc theo đoạn văn chính xác giúp kiểm toán nhưng không chứng minh rằng đoạn đó đã được dịch sang công thức đúng.

Chứng kiến có vai trò chặn đoán chứ không sửa lỗi: nó chỉ ra sự bất đồng nhưng không nói quan hệ còn thiếu nào được nguồn cho phép. Mô hình ngôn ngữ đề xuất quan hệ, cổng tắt định quyết định quan hệ có được vào đặc tả tin cậy hay không. Nếu một bổ sung được chấp nhận vẫn tạo cặp phân kỳ mới, vòng thứ hai và cuối nhận chặn đoán cập nhật. Đề xuất bị bác không làm biến đổi từng phần F . Vòng lặp do đó bị chặn và không cần rollback, khác với tự tinh chỉnh không ràng buộc nơi nhiều lần chỉnh sửa có thể làm mờ căn cứ.

3.4 Cài đặt tin cậy và ngữ nghĩa sửa chữa

Cài đặt biên dịch một cây cú pháp biểu thức bị giới hạn sang Z3 [17], từ chối lời gọi tùy ý, tên chưa khai báo, phép so sánh sai dạng và toán tử không được hỗ trợ. Ánh xạ biến độc lập ngăn hai bản sao dùng chung biến. Việc kiểm tra căn cứ là cổng triển khai tắt định, không phải chỉ là câu lệnh trong prompt; cả đề xuất thô và kết quả qua cổng đều được lưu. Cơ sở tin cậy gồm parser, compiler, solver và gate; mô hình ngôn ngữ vẫn là thành phần không đáng tin.

Khai báo nguyên, thực, Boolean có kiểu rõ ràng; cận khai báo được biên dịch thành ràng buộc. Backend tính toán và kiểm chứng dùng cùng một ModelSpec chuẩn hóa. Mỗi bản ghi lưu phán quyết ban đầu, hành động đề xuất, đoạn nguồn, lý do từ chối, phán quyết cuối, cấu hình mô hình và băm prompt. Vết kiểm toán này tách hành vi mô hình khỏi hành vi cưỡng chế của hệ thống.

Cho $\text{span}(c)$ là đoạn nguồn được dẫn cho ứng viên c , và $\mathcal{R}$ là tập đóng bằng các quy tắc ngữ nghĩa miền. Cổng chấp nhận chính xác khi

$$\begin{aligned} \text{Accept}(c) \iff & \text{Compiles}(c) \wedge \text{Grounded}(c, P, \mathcal{R}) \\ & \wedge \text{SAT}(F \wedge c) \wedge \neg(F \models c) \wedge \text{Det}(F \wedge c, q). \end{aligned} \quad (2)$$

Đề xuất đầu tiên được chấp nhận sẽ được ghi nhận; nếu không, F được giữ nguyên. Vì vậy, phát biểu lặp lại, ghim đích không được nguồn hỗ trợ và bổ sung chưa đủ không nhận điểm sửa chữa; một biểu thức được hỗ trợ không cần trùng cú pháp vàng.

Kích thước mã hóa tuyến tính theo $|F|$, dù thời gian giải phụ thuộc lý thuyết. Đầu vào đã xác định không cần gọi sửa chữa; đầu vào mơ hồ tồn tại đa hai lời gọi cùng các lần kiểm tra lại. Hệ thống giữ riêng các trạng thái: unsupported cho giới hạn biểu diễn, unknown khi solver không kết luận, inconsistent khi F bất khả thỏa và underspecified khi đích mơ hồ nhưng không có sửa chữa có căn cứ.

Các trạng thái này dẫn đến hành động bộ điều khiển khác nhau. Cấu trúc không được hỗ trợ phải chuyển sang công cụ hoặc compiler rộng hơn; truy vấn không kết luận có thể cần ngân sách solver lớn hơn; mô hình bất nhất cần sửa mã hóa; nguồn thiếu đặc tả cần hỏi lại hoặc từ chối. Gộp cả bốn thành “thất bại” làm cho báo cáo độ phủ và hành vi tác tử khó diễn giải. Tương tự, phán quyết xác định chỉ cho phép trả lời trong phạm vi F , không khẳng định nguồn đã được hình thức hóa đầy đủ.




Figure 1: DeGro trong pipeline suy luận thực thi được. SymCode sinh tạo phẩm thực thi; DeGro chuyển ModelSpec có cấu trúc cho phép kiểm chứng tính xác định dựa trên Z3. Đích xác định có thể được trả lời; đích mơ hồ đi vào sửa chữa có căn cứ hoặc từ chối; kiểm tra không kết luận không tạo chứng nhận.

3.5 Tích hợp tác tử và ngữ nghĩa bộ điều khiển

DeGro là một chính sách kiểm chứng nằm trong tác tử lớn hơn. Nó biến tạo phẩm thực thi được thành quan sát có kiểu để bộ điều khiển ánh xạ sang hành động.

Trạng thái	Bảng chứng	Hành động bộ điều khiển
Determinate	F sat, Φ unsat	trả lời kèm phạm vi
Ambiguous	các đích bất đồng	sửa chữa có căn cứ
Inconsistent	F unsat	sửa biểu diễn
Unknown	solver không kết luận	fallback/chuyển cấp
Unsupported	ngoài mảnh hỗ trợ	dùng công cụ khác
Underspecified	không có sửa chữa có căn cứ	hỏi lại hoặc từ chối

Trong tương tác, underspecified có thể yêu cầu làm rõ; benchmark chấm hành động từ chối vì không có kênh bổ sung thông tin. Việc tách sinh, kiểm chứng tất định và sửa chữa làm giảm tự xác nhận và tạo vết kiểm toán. Giao diện nên nói “các ràng buộc đã mã hóa xác định đại lượng đích”, không nên nói đề bài đã được chứng minh hình thức.

4 Thí nghiệm và kết quả

4.1 Thiết lập thí nghiệm

Benchmark ghép cặp có kiểm soát. Với mỗi đặc tả vàng $F^* = \{c_1, \dots, c_k, c^*\}$, tác giả tạo $F^- = F^* \setminus \{c^*\}$ và chỉ giữ lại khi F^* xác định đích còn F^- khả thỏa nhưng đích mơ hồ. Mỗi cặp dùng chung F^- : nguồn omission chứa sự kiện cho c^* và cần sửa; nguồn underspecified bỏ sự kiện ấy và cần từ chối. Chỉ nhìn trạng thái verifier không thể đoán nhãn. Sau khi loại một pilot 80 cặp và tập phát triển 100 cặp, nhóm tác giả đóng băng 120 cặp MIRA-Math xác nhận (240 trường hợp, năm họ) [1]; phân tích gộp 300 cặp chỉ là thứ cấp.

Kiểm tra toàn vẹn. Bộ dựng nhập sự kiện thiếu có kiểu từ MIRA-Math thay vì nhờ LLM phá hỏng đề, rồi áp dụng cả ba kiểm tra solver. Tập cuối dùng hết các định danh chưa thấy nhưng tương thích; manifest ghi bản sửa nguồn 72ff918, giấy phép, seed chọn, số lượng theo họ và băm prompt/đầu ra. Năm họ gồm phân tách tuyến tính, hệ thiếu hạng, tổng đường đi, tái dựng theo định lý số dư Trung Hoa và ràng buộc moment. Vì mọi phép xóa được giữ lại đều được kiểm chứng cơ học là tối quan trọng cho đích, benchmark không gán nhằm một thiếu sót không liên quan thành cơ hội sửa chữa.

Phương pháp và giả thuyết. Bốn phương pháp được so sánh: self-review, grounded self-review, determinacy-guided repair và DeGro, với cùng biểu diễn ban đầu và ngân sách hai lần thử. GPT-OSS 20B và Gemma 4 31B dùng reasoning trung bình, nhiệt độ 1.0 và prompt đóng băng; mỗi mô hình có đủ $120 \times 2 \times 4 = 960$ bản ghi. Một tập khám phá 100 cặp độc lập so sánh chỉ-phán-quyết và các biến thể có chứng kiến cho RQ3.

Self-review nhận tạo phẩm thực thi và được yêu cầu sửa mà không có chẵn đoán hình thức. Grounded self-review thêm yêu cầu trích nguồn như DeGro. Determinacy-guided repair nhận phán quyết solver có kiểu nhưng không có tương tác kiểm tra căn cứ, nhờ đó tách riêng tín hiệu chẵn đoán. DeGro kết hợp tín hiệu với bằng chứng nguồn và áp dụng cùng công chấp nhận tất định dùng khi chấm. Vì mọi phương pháp bắt đầu từ cùng F^- , khác biệt không thể quy cho chất lượng sinh ban đầu.

So sánh chính đã đăng ký trước kiểm tra DeGro có tăng FDA so với grounded self-review hay không. Kiểm định riêng từng mô hình bằng McNemar ghép cặp chính xác và hiệu chỉnh Holm cho hai kiểm định. Hiệu ứng được báo theo điểm phần trăm cùng khoảng bootstrap cụm-cặp 95%.

Thước đo. Tỷ lệ sửa chữa thành công (RSR) đòi hỏi bổ sung có căn cứ và đúng chức năng; tỷ lệ từ chối đúng (CAR) thưởng cho từ chối trên ca thiếu đặc tả. Độ chính xác quyết định cuối (FDA) lấy trung bình trên hai loại ca cân bằng; tỷ lệ sửa quá mức là $1 - \text{CAR}$; sửa không được hỗ trợ (UR) là tỷ phần bổ sung thiếu nguồn hỗ trợ. Kết quả ngữ nghĩa, chức năng và căn cứ được giữ riêng.

Nghiên cứu lỗi tự nhiên. Để đánh giá tính sinh thái, GPT-OSS 20B sinh một đặc tả Structured SymCode cho mỗi bài MATH-500 mà không cài lỗi. Tất cả ca phân tích được, solver hỗ trợ và có kết luận được đóng băng trước khi gán nhãn hoặc xem kết quả; mỗi phương pháp dùng lại đặc tả ban đầu đó. Nhấn và bằng chứng do mô hình đề xuất bị che khỏi đầu ra verifier, rồi hai người kiểm tra toàn bộ 292 ca MATH-500 và 503 ca ALG514. Do không lưu nhấn độc lập trước thảo luận, bài báo chỉ tuyên bố *kiểm tra bởi con người*, không tuyên bố chú giải độc lập hay độ đồng thuận liên chú giải.

Nhãn gồm: đúng, thiếu/sai/thừa ràng buộc, sai miền, sai đích, lỗi tính toán và khác; chỉ thiếu sót tối quan trọng cho đích và được nguồn hỗ trợ mới vào tập dương chính. GPT-OSS 20B và Gemma 4 31B đề xuất nhãn MATH-500 khi không biết tính xác định, chứng kiến, sửa chữa và kết quả phương pháp. Với ALG514, GPT-OSS 120B đề xuất 503 nhãn và xem lại 22 ca nơi trạng thái ngữ nghĩa khác trạng thái số tương thích với verifier; người đánh giá kiểm tra tất cả nhãn cuối.

Đơn vị phân tích là đề bài gốc; mọi phương pháp dùng chung hình thức hóa ban đầu. Recall hỏi DeGro phát hiện được bao nhiêu thiếu sót tối quan trọng đã kiểm chứng; precision hỏi bao nhiêu phán quyết mơ hồ thực sự thuộc lớp đó. Sửa chữa có điều kiện đếm bản sửa được chấp nhận trong các thiếu sót đã phát hiện, còn sửa chữa đầu-cuối giữ mọi thiếu sót đã kiểm chứng trong mẫu số. MATH-500 có 292/500 hình thức hóa kết luận được và được solver hỗ trợ; ALG514 có 503/514. DRAW-1K bị bỏ vì kết quả verifier đã sửa và nhãn người cuối chưa đầy đủ.

4.2 Kết quả chính

Bảng dưới báo phân tích xác nhận 120 cặp. Với GPT-OSS 20B, DeGro tăng FDA từ 90.0% lên 95.0% so với grounded self-review: +5.0 điểm (CI 95% [0.4, 9.6]; số cặp bất đồng 22 so với 10; McNemar chính xác $p = .050$, Holm $p = .100$). Với Gemma 4 31B, FDA đổi từ 97.9% xuống 97.5%: -0.4 điểm (CI 95% [-3.3, 2.5]; 5 so với 6; $p = 1.0$). Kết quả xác nhận vì vậy ủng hộ mức tăng thực tiễn với GPT-OSS nhưng không ủng hộ lợi thế chung cho mọi mô hình. Kết quả Gemma cao nhất là phương pháp tính xác định chỉ có phán quyết (99.6% FDA), cho thấy tương tác căn cứ bổ sung tự nó cũng có thể gây lỗi.

Mô hình	Phương pháp	RSR $\uparrow$	CAR $\uparrow$	FDA $\uparrow$	ORR $\downarrow$	UR $\downarrow$
GPT-OSS 20B	Self-review	93.3	87.5	90.4	12.5	15.2
	Grounded self-review	100.0	80.0	90.0	20.0	16.7
	Determinacy-guided	86.7	99.2	92.9	0.8	6.3
	DeGro	92.5	97.5	95.0	2.5	4.3
Gemma 4 31B	Self-review	100.0	93.3	96.7	6.7	6.3
	Grounded self-review	100.0	95.8	97.9	4.2	4.0
	Determinacy-guided	100.0	99.2	99.6	0.8	0.8
	DeGro	100.0	95.0	97.5	5.0	4.8

Phân tích gộp thứ cấp. Trên toàn bộ 300 cặp, DeGro so với grounded self-review đổi FDA từ 91.2% lên 96.2% cho GPT-OSS (chênh +5.0 điểm, CI 95% [2.3, 7.7]; McNemar $p < .001$) và từ 96.2% lên 97.8% cho Gemma (chênh +1.7 điểm, CI 95% [-0.2, 3.5]; $p = .099$). Các ước lượng này gồm dữ liệu phát triển và không thay thế kiểm định xác nhận 120 cặp.

Lỗi tự nhiên do con người kiểm tra. Trong nhóm MATH-500 được hỗ trợ, 158/292 hình thức hóa là đúng; còn lại gồm 69 sai đích, 32 sai ràng buộc, 24 thiếu ràng buộc tối quan trọng cho đích, 8 thừa ràng buộc và 1 sai miền. Bộ phát hiện tìm được 21/24 thiếu sót (recall 87.5%, CI Wilson 95% [69.0, 95.7]) nhưng precision chỉ 17.4% (21/121), và chỉ một thiếu sót được sửa thành công đầu-cuối (1/24 = 4.2%). Dù vậy, DeGro tăng độ chính xác đáp án của cả nhóm từ 49.3% (144/292) lên 53.8% (157/292); 16 ca bất đồng nghiêng về DeGro và 3 ca nghiêng về baseline có cấu trúc (McNemar $p = .0044$). Tỷ lệ này có điều kiện trên độ phủ mảnh solver 58.4%.

ALG514 [45] tạo tương phản độ phủ cao: 503/514 ca vào nhóm kiểm chứng, gồm 477 đúng, 11 sai đích, 8 thiếu ràng buộc và 7 sai ràng buộc. Tỷ lệ lỗi ngữ nghĩa là 5.2% (CI Wilson 95% [3.6, 7.5]). Structured Solver và DeGro lần lượt đạt 94.2% (484/514) và 94.4% (485/514), dùng so khớp tập con bất biến thứ tự với dung sai 10^{-3} cho vector nghiệm làm tròn của ALG514. Chín đáp án tương

thích số vẫn mang lỗi ngữ nghĩa do người kiểm tra, cho thấy đánh giá chỉ theo đáp án có thể che lỗi biểu diễn. Mức tăng một ca trên ALG514 chỉ có tính khám phá.

4.3 Phân rã phát hiện–sửa chữa

Kết quả lỗi tự nhiên tách ba câu hỏi mà một điểm đáp án tổng hợp thường trộn lẫn. Thứ nhất, độ phủ biểu diễn hỏi ngôn ngữ có cấu trúc và solver có biểu đạt, quyết định được mô hình sinh ra hay không. Thứ hai, phát hiện mơ hồ hỏi có tồn tại hai phép gán phân kỳ đích trong mô hình hay không. Thứ ba, sửa chữa có căn cứ hỏi nguồn gốc có hỗ trợ ràng buộc mới loại bỏ bất đồng hay không. MATH-500 đạt mức vừa ở tầng một (292/500), recall mạnh ở tầng hai (21/24) và rất yếu ở tầng ba (1/24). Nút thắt vì vậy không chỉ là phát hiện không duy nhất, mà là biến phản ví dụ solver thành một chỉnh sửa ngữ nghĩa đúng và có trích dẫn.

Precision cho góc nhìn bổ sung. Chỉ 21/121 đặc tả MATH-500 mơ hồ là thiếu sót tối quan trọng cho đích đã kiểm chứng. Các ca mơ hồ còn lại gồm sai đích, sai ràng buộc và miền nghiệm rộng vì nguyên nhân khác với thiếu sự kiện nguồn. Đây là cảnh báo hợp lệ về F nhưng không phải cơ hội sửa bằng phép cộng ràng buộc. Do đó, bộ phát hiện recall cao vẫn cần củng cố nghiêm ngặt; tự động coi mọi mơ hồ là thiếu sót sẽ lặp lại hành vi sửa quá mức của self-review chung.

Độ chính xác đáp án cũng làm nhẹ đi khác biệt ngữ nghĩa. Trên MATH-500, DeGro đổi baseline có cấu trúc từ 49.3% lên 53.8%, nhưng chỉ một thiếu sót được sửa đầu-cuối; phần lớn thay đổi đáp án không chứng minh rằng cơ chế tìm quan hệ thiếu đã được giải quyết. Trên ALG514, chín đầu ra tương thích số vẫn có lỗi ngữ nghĩa. Vì thế bài báo báo riêng kết quả số, ngữ nghĩa, chức năng, căn cứ và tính xác định.

Cách đọc theo lý thuyết quyết định. FDA đặt khối lượng bằng nhau cho sửa nguồn đầy đủ và từ chối nguồn thiếu đặc tả vì mỗi mục kiểm soát có một ca mỗi loại. Ứng dụng thực có thể phạt bìa đặt nặng hơn bỏ lỡ sửa chữa. Dữ liệu mức-ca cho phép chọn utility khác, nhưng đánh đổi đã thấy rõ: grounded review chung đạt RSR cao nhưng sửa quá mức, còn phán quyết tính xác định trần có xu hướng từ chối. DeGro cố lấy lại sửa chữa hữu ích mà vẫn giữ biên hành động bảo thủ. Cân bằng nào tốt hơn phụ thuộc chi phí downstream của một khẳng định không được hỗ trợ.

4.4 Ablation chứng kiến

Trên tập khám phá 100 cặp, DeGro đạt FDA 98.5 so với 97.5 khi có chứng kiến (năm so với ba bất đồng nghiêng về DeGro; p Holm = .727). Chứng kiến tối giản tăng RSR sáu điểm so với chỉ phán quyết nhưng cũng không có ý nghĩa (p = .714). Vì vậy, phép gán cụ thể không đem lại lợi ích đo được trong thiết lập này: phán quyết có kiểu có thể hiển thị mặc định, còn chứng kiến giữ lại để kiểm toán hoặc cho ca khó hơn.

Phương pháp	RSR	CAR	FDA	ORR
Self-review	92	84	88.0	16
Chỉ báo không duy nhất	87	97	92.0	3
Chứng kiến tối giản	93	93	93.0	7
Chứng kiến đích	86	94	90.0	6
Chứng kiến tối giản + căn cứ	97	99	98.0	1
DeGro	97	100	98.5	0
DeGro + chứng kiến	97	98	97.5	2

Kết quả âm này thu hẹp đóng góp. Mọi ca kiểm soát đều có một thiếu sót tối quan trọng cho đích, nên tín hiệu không duy nhất đã định vị lỗi đủ tốt; phép gán chứng kiến thêm token nhưng ít thông

tin mới. Đặc tả có nhiều sự kiện thiếu hoặc nhiều chiều phụ có thể khác, song dữ liệu hiện tại ủng hộ grounding được tính xác định dẫn đường, không ủng hộ lợi ích phổ quát của việc đưa phép gán cụ thể cho mô hình.

4.5 Mẫu lỗi và hành vi xuyên mô hình

Trên tập gộp, self-review chung của GPT-OSS sửa hơn 92% thiếu sót nhưng CAR nhiều nhất chỉ 87%. Phán quyết trần nâng CAR lên 98% nhưng hạ RSR xuống 87.7%; DeGro khôi phục sửa chữa, giữ CAR 99% và giảm bổ sung không được hỗ trợ từ 12.5% xuống 3.4% so với grounded self-review. Gemma sửa mọi thiếu sót; phán quyết trần đạt FDA 99.0 còn DeGro đạt 97.8, với tỷ lệ bổ sung không được hỗ trợ 2.0% và 4.2%. Hiệu ứng theo họ tập trung: GPT tăng 20.8 điểm ở phân tách tuyến tính nhưng DeGro chỉ đạt 87.5% trên hệ thiếu hạng. Hiệu ứng tổng hợp không đồng đều và không độc lập mô hình.

Họ bài toán	GPT-OSS 20B		Gemma 4 31B	
	GSR	DeGro	GSR	DeGro
Tái dựng CRT	100.0	99.2	100.0	100.0
Tổng đường đi đồ thị	96.7	99.2	99.2	100.0
Phân tách tuyến tính	76.7	97.5	85.8	90.8
Bài toán moment	88.3	97.5	98.3	100.0
Hệ thiếu hạng dùng chung	94.2	87.5	97.5	98.3

Các điểm trung bình giống nhau có thể đến từ cơ chế khác nhau. GPT review chung thường chèn một quan hệ hợp lý nhưng không được phát biểu trong ca phân tách tuyến tính; DeGro chặn phần lớn bổ sung đó. Ở hệ thiếu hạng, cùng tín hiệu lại khuyến khích từ chối dù nguồn đầy đủ hỗ trợ sửa chữa. Gemma gần trần ở bốn họ nên ít dư địa. Một điểm trung bình duy nhất sẽ che cả chế độ có lợi và bất lợi.

4.6 Kiểm toán độ phủ benchmark rộng

GPT-OSS 20B sinh một Structured SymCode dùng chung cho mỗi bài MATH-500 [26]. Trong 500 đặc tả, 292 (58.4%) phân tích được, đến được solver và tạo phán quyết kết luận; bảng sau giải thích mọi loại bị loại.

Tình trạng	Số lượng	Phần trăm
Kết luận được và solver hỗ trợ	292	58.4
Không hỗ trợ ở mức mô hình	65	13.0
Không hỗ trợ ở mức solver	112	22.4
Bất nhất	9	1.8
Solver unknown	9	1.8
Lỗi gọi	13	2.6
Tổng	500	100.0

Độ phủ được cố định chỉ từ phân tích cú pháp và trạng thái solver, không từ đáp án quan sát. Ca không hỗ trợ ở mức solver chiếm nhiều nhất và cần lý thuyết/compiler rộng hơn; lỗi ở mức mô hình cần sinh có cấu trúc tốt hơn. Độ chính xác có điều kiện nói về 292 bài được hỗ trợ, còn độ chính xác đầu-cuối tính thất bại cho 208 bài khác. Mọi bản ghi Structured Solver hoàn tất; DeGro hoàn

tất 285, với sáu lỗi gọi và một bản ghi không hỗ trợ. Mẫu số đóng băng được giữ và cả bảy đều tính sai.

Tách như vậy ngăn chặn lát độ phủ thuận lợi hậu nghiệm. Độ chính xác có điều kiện hồi tác từ làm tốt đến đâu sau khi đặc tả đạt trạng thái solver kết luận; độ chính xác đầu-cuối còn tính mọi lỗi biểu diễn và thực thi. Chỉ báo loại đầu sẽ khiến verifier hẹp trông cạnh tranh với sinh chương trình không hạn chế trong khi che 41.6% benchmark. Các loại loại trừ cũng chỉ đúng thành phần cần cải thiện.

5 Thảo luận và hạn chế

Diễn giải và độ giá trị

Thiết kế ghép cặp giữ cố định giá trị ẩn, đích, miền, ràng buộc còn lại và phán quyết solver; chỉ mức hỗ trợ nguồn cho c^* thay đổi. Chính sách sửa chữa không nhận c^* , đích vàng hay hành động vàng. 120 cặp xác nhận được đóng băng trước khi kiểm tra, với kiểm định và hiệu chỉnh Holm khai báo trong manifest. Phân tích gộp vẫn là thứ cấp, ablation chứng kiến là khám phá. FDA cân bằng sửa chữa và từ chối đúng; UR phải đọc cùng RSR và CAR vì luôn từ chối sẽ có zero bổ sung không hỗ trợ nhưng cũng không có ích lợi sửa chữa.

Một hỗn hợp thông thường của câu hỏi đầy đủ và thiếu cho phép đường tắt: các họ khác độ khó, cách viết có thể báo thiếu sự kiện, và chính sách có thể học sửa mọi trạng thái mơ hồ. Ghép cặp loại các đường tắt này vì hai thành viên dùng chung hình thức hóa và chẩn đoán. Hành vi đúng chỉ thay đổi theo mức hỗ trợ ngôn ngữ tự nhiên cho ràng buộc bị giữ lại. McNemar chính xác chỉ phụ thuộc cặp hai chính sách bất đồng; bootstrap cụm-cặp giữ phụ thuộc giữa hai loại ca.

So sánh chính cũng kiểm soát giao diện mô hình: hai phương pháp nhận cùng nguồn, đặc tả, schema đầu ra, yêu cầu grounding, mô hình và ngân sách token; tín hiệu tính xác định được thêm là can thiệp dự kiến. Giá trị ẩn vàng chỉ dùng sau sinh để chấm. Ghim trực tiếp đích bị coi là không được hỗ trợ trừ khi có đoạn nguồn cho phép và mọi cổng ngữ nghĩa, chức năng, tính xác định chấp nhận. Lưu cả đầu ra thô và qua cổng làm lộ khi độ chính xác có vẻ cao được mua bằng bja đặt.

Phạm vi tuyên bố

Bằng chứng ủng hộ tính xác định đích như hàng rào chống sửa chữa hợp lý nhưng không được phát biểu, gồm mức tăng năm điểm với GPT-OSS. Nó không thiết lập tương đương ngữ nghĩa giữa P và F , lợi ích grounding phổ quát, lợi ích tăng thêm của chứng kiến, hay ưu thế trước sinh mã không hạn chế. Đoạn nguồn chính xác là nguồn gốc có thể kiểm toán, không phải hệ quả ngữ nghĩa. Độ tin cậy và tính xác định bổ sung nhau: tin cậy thấp có thể khiến fallback dù đích xác định; tin cậy không thể cho phép trả lời khi đích mơ hồ.

Phân biệt này quan trọng cho thiết kế tác tử. Bộ theo dõi thực thi hỏi tạo phẩm có chạy không; verifier kết quả kiểm tra đáp án cuối; DeGro đặc trưng miền khả thi trước khi tác tử cam kết một giá trị. Chứng nhận trung gian này hỗ trợ hành động chọn lọc: trả lời khi đích xác định, chỉ sửa khi sự kiện nguồn có trích dẫn khôi phục tính xác định, nếu không thì hỏi, từ chối hoặc chuyển cấp. Nó không chứng minh hình thức hóa khớp nguồn. Một mô hình giải đúng nhưng dịch sai vẫn có thể xác định.

Grounding cũng chỉ là đại diện gần đúng. Mô hình có thể trích đúng câu nhưng mã hóa sai phương trình; ngược lại, quy ước toán học ngầm có thể biện minh cho biểu thức mà không có đoạn liên tục. Vì vậy, bài báo giữ riêng tính hợp lệ ngữ nghĩa, chức năng, nguồn gốc và tính xác định solver. Sự phân rã này làm bất đồng có thể kiểm toán và ngăn đáp án số đúng nuốt mất lỗi dịch.

Độ giá trị bên ngoài

Ca MIRA có kiểm soát nhưng theo mẫu; MATH-500 tự nhiên nhưng chỉ 58.4% nằm trong mảnh solver, còn ALG514 đạt 97.9% độ phủ ở miền hẹp hơn. Nhấn được người kiểm tra sau đề xuất của mô hình, không phải chú giải độc lập; tỷ lệ phổ biến được báo riêng. Lỗi tự nhiên chỉ có 24 thiếu sót MATH-500 và 8 thiếu sót ALG514 tối quan trọng cho đích: phát hiện cao nhưng sửa chữa hạn chế. GPT-OSS và Gemma cũng khác nhau, trực tiếp giới hạn mọi tuyên bố xuyên mô hình.

Benchmark kiểm soát cố ý xóa một sự kiện đã biết, nên ước lượng quyết định sạch giữa sửa và từ chối dưới kiểm soát biểu diễn lý tưởng. Nó thể hiện chưa đủ paraphrase, văn bản không liên quan, sơ đồ, quy ước ngầm, ràng buộc sai và lỗi dịch tương tác. Các nhóm tự nhiên chứa hiện tượng này nhưng mất kiểm soát nhân quả. Hai loại bổ sung nhau: benchmark ghép cặp nhận diện hiệu ứng chính sách, nghiên cứu tự nhiên ước lượng điều pipeline hiện tại gặp. Chúng không được gộp thành một con số xếp hạng.

Quy trình chú giải tránh định nghĩa ca dương bằng chính phán quyết của DeGro. Đầu ra bộ phát hiện, sửa chữa, tên phương pháp và đáp án downstream bị che khỏi gói ban đầu. Thiếu sót tối quan trọng phải được thiết lập từ nguồn và đặc tả sinh; ca đúng, sai ràng buộc, sai đích, sai miền vẫn ở mẫu số. Vì đề xuất mô hình khởi tạo quá trình review và không lưu nhãn mù độc lập trước thảo luận, tuyên bố phù hợp là kiểm tra bởi con người chứ không phải độ tin cậy liên chú giải.

Khả năng tái lập và rủi ro

Artifact chứa compiler, truy vấn hai bản sao, cổng, kiểm thử, builder, manifest đóng băng, prompt, bản ghi thô và phân tích. Bấm đầu ra xác nhận là 5616d0c6...4ce3f0b; mỗi phân tích mô hình dùng đủ 960 bản ghi kỳ vọng. Tính xác định vẫn phụ thuộc F : ràng buộc sai/thừa có thể ép đích sai nhưng duy nhất, thiếu sót không ảnh hưởng đích là vô hình, và mảnh SMT hiện tại loại nhiều suy luận phi tuyến, siêu việt và sơ đồ. Giao diện phải lộ phạm vi này thay vì ngụ ý chân lý. Dữ liệu không chứa thông tin cá nhân; trợ giúp AI phải được công bố theo quy định hội nghị và không giảm trách nhiệm tác giả.

Manifest ghi bản sửa và giấy phép tập dữ liệu, seed chọn, số lượng họ, tên mô hình chính xác, cấu hình giải mã, bấm prompt, timestamp và bấm đầu ra đầy đủ. Script phân tích dựng lại mọi bảng từ JSONL, bác số lượng cặp kỳ vọng không đủ và lưu nguồn pilot/phát triển/xác nhận. Gói lỗi tự nhiên cùng nhãn kiểm chứng được làm mù và định địa chỉ theo nội dung. Nhờ vậy, kết quả chính 120 cặp có thể tái lập mà không trộn quan sát trước đó.

Nhiều lỗi nằm ngoài chứng nhận: ràng buộc sai hoặc thừa có thể ép một đích duy nhất nhưng sai; sự kiện thiếu không ảnh hưởng q là vô hình; nhiều thiếu sót tương tác có thể vượt ngân sách sửa chữa; chứng kiến có thể chỉ khác trên biến không liên quan. Mảnh SMT không bao phủ nhiều toán phi tuyến, siêu việt và sơ đồ. Đây là lý do phải hiển thị ràng buộc đã mã hóa, sửa chữa được trích dẫn và trạng thái solver, chứ không phải hiển thị huy hiệu “đã kiểm chứng” vô điều kiện.

Hai mô hình có hành vi làm theo chỉ dẫn và từ chối khác nhau; checkpoint được host có thể thay đổi. Lợi thế của DeGro nên được xem là thuộc tính của một cấu hình mô hình–prompt–gate xác định. Kết quả không tăng của Gemma có ý nghĩa: thêm tương tác grounding trông nghiêm ngặt hơn không tự động đơn điệu về an toàn. Cổng tắt định vẫn cần thiết; ngưỡng triển khai phải phản ánh chi phí tương đối giữa bịa sự kiện và bỏ lỡ sửa chữa.

Hàm ý triển khai

DeGro phù hợp nhất như tín hiệu định tuyến, không phải huy hiệu đúng đắn phổ quát. Đặc tả xác định và được hỗ trợ có thể sang sinh đáp án; đặc tả mơ hồ có ứng viên có căn cứ vào vòng sửa bị chặn; đặc tả mơ hồ không có hỗ trợ phải hỏi lại hoặc từ chối. Ca bắt nhất, không kết luận và không

hỗ trợ cần fallback khác nhau. Giữ trạng thái có kiểu ngăn tác tử coi thiếu chứng nhận solver là giấy phép đoán.

Kết quả cũng gợi ý giao diện bảo thủ. Hệ thống nên hiển thị biểu thức đích, ràng buộc mã hóa liên quan, trạng thái tính xác định và đoạn nguồn dùng cho sửa chữa. Khi có chứng kiến, nó có thể giữ trong nhật ký kiểm toán dù prompt mặc định chỉ nhận phán quyết. Điều này phù hợp ablation: chứng kiến là bằng chứng cơ học có giá trị nhưng đưa nó cho mô hình sửa chữa không tăng quyết định trên benchmark hiện tại. Người dùng nhờ đó phân biệt “mô hình hiện tại cố định đại lượng này” với tuyên bố mạnh hơn nhưng không được hỗ trợ rằng toàn bộ phép dịch là đúng.

So sánh triển khai phải báo độ phủ biểu diễn, chất lượng quyết định có điều kiện trên trạng thái verifier kết luận, và ích lợi đầu-cuối trong đó ca không hỗ trợ, unknown và lỗi gọi được giữ như thất bại. Nếu không, verifier ký hiệu hẹp có thể trông rất đáng tin chỉ vì từ chối đầu vào khó trước khi chấm.

6 Kết luận

DeGro kiểm tra liệu các mô hình khả thi có đồng thuận về đại lượng một tác tử sẽ báo hay không, rồi dùng sửa chữa có căn cứ từ nguồn hoặc từ chối. Nó cải thiện GPT-OSS 20B năm điểm FDA trên 120 cặp đăng ký trước nhưng không cải thiện Gemma; chứng kiến cụ thể không đem lại lợi ích đo được. Trên lỗi tự nhiên, phát hiện vượt xa sửa chữa thành công. Vì vậy, tính xác định của đại lượng đích là điều kiện an toàn hữu ích nhưng phụ thuộc biểu diễn; việc đánh giá nó phải bao gồm hành vi grounding, độ phủ solver và ranh giới giữa văn bản nguồn với hình thức hóa.

Tên bài báo và thông tin thư mục dưới đây được giữ nguyên như bản tiếng Anh để thuận tiện tra cứu.

Tài liệu tham khảo

- [1] Charbel Al Bateh and Samer Saab Jr. Mira-math: A benchmark for minimal information requesting and mathematical reasoning. *arXiv preprint arXiv:2607.07391*, 2026.
- [2] Mohannad Alhanahnah, Md Rashedul Hasan, and Hamid Bagheri. An empirical evaluation of pre-trained large language models for repairing declarative formal specifications. *arXiv preprint arXiv:2404.11050*, 2024.
- [3] Anastasios N. Angelopoulos, Stephen Bates, Adam Fisch, Lihua Lei, and Tal Schuster. Conformal risk control. In *International Conference on Learning Representations*, 2024.
- [4] Paul C. Attie, Kinan Dak Al Bab, and Mouhammad Sakr. Model and program repair via SAT solving. *ACM Transactions on Embedded Computing Systems*, 17(2), 2017. doi: 10.1145/3147426.
- [5] Zhangir Azerbayev, Bartosz Piotrowski, Hailey Schoelkopf, Edward W. Ayers, Dragomir Radev, and Jeremy Avigad. Proofnet: Autoformalizing and formally proving undergraduate-level mathematics. *arXiv preprint arXiv:2302.12433*, 2023.
- [6] Zhangir Azerbayev, Hailey Schoelkopf, Keiran Paster, Marco Dos Santos, Stephen McAleer, Albert Qiaochu Jiang, Jia Deng, Stella Biderman, and Sean Welleck. Llemma: An open language model for mathematics. In *International Conference on Learning Representations*, 2024.
- [7] Sina Bagheri Nezhad, Yao Li, and Ameeta Agrawal. Symcode: A neurosymbolic approach to mathematical reasoning via verifiable code generation. In *Findings of the Association for Computational Linguistics: EACL 2026*, pages 1489–1503. Association for Computational Linguistics, 2026. doi: 10.18653/v1/2026.findings-eacl.76. URL <https://aclanthology.org/2026.findings-eacl.76/>.
- [8] Gilles Barthe, Pedro R. D’Argenio, and Tamara Rezk. Secure information flow by self-composition. In *17th IEEE Computer Security Foundations Workshop*, pages 100–114, 2004. doi: 10.1109/CSFW.2004.1310735.

- [9] Gilles Barthe, Juan Manuel Crespo, and César Kunz. Relational verification using product programs. In *FM 2011: Formal Methods*, volume 6664 of *Lecture Notes in Computer Science*, pages 200–214, 2011. doi: 10.1007/978-3-642-21437-0_17.
- [10] Wenhui Chen, Xueguang Ma, Xinyi Wang, and William W. Cohen. Program of thoughts prompting: Disentangling computation from reasoning for numerical reasoning tasks. *Transactions on Machine Learning Research*, 2023.
- [11] Edmund M. Clarke, Orna Grumberg, Somesh Jha, Yuan Lu, and Helmut Veith. Counterexample-guided abstraction refinement. In *Computer Aided Verification*, volume 1855 of *Lecture Notes in Computer Science*, pages 154–169, 2000. doi: 10.1007/10722167_15.
- [12] Michael R. Clarkson and Fred B. Schneider. Hyperproperties. *Journal of Computer Security*, 18(6): 1157–1210, 2010. doi: 10.3233/JCS-2009-0393.
- [13] Michael R. Clarkson, Bernd Finkbeiner, Masoud Kolehini, Kristopher K. Micinski, Markus N. Rabe, and César Sánchez. Temporal logics for hyperproperties. In *Principles of Security and Trust*, volume 8414 of *Lecture Notes in Computer Science*, pages 265–284, 2014. doi: 10.1007/978-3-642-54792-8_15.
- [14] Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. Training verifiers to solve math word problems. In *arXiv preprint arXiv:2110.14168*, 2021.
- [15] Corinna Cortes, Giulia DeSalvo, and Mehryar Mohri. Learning with rejection. In *Algorithmic Learning Theory*, volume 9925 of *Lecture Notes in Computer Science*, pages 67–82, 2016. doi: 10.1007/978-3-319-46379-7_5.
- [16] Wenyao Cui, Huaping Zhang, Yongyi Huang, Qiuchi Li, Jian Xu, Cheng-Lin Liu, Chunxiao Gao, Juan Wang, and Baohua Zhang. Symdiag: Explainable diagnosis for llm reasoning via neuro-symbolic verification. *arXiv preprint arXiv:2608.08786*, 2026.
- [17] Leonardo de Moura and Nikolaj Bjørner. Z3: An efficient SMT solver. In *Tools and Algorithms for the Construction and Analysis of Systems*, volume 4963 of *Lecture Notes in Computer Science*, pages 337–340. Springer, 2008. doi: 10.1007/978-3-540-78800-3_24.
- [18] Isil Dillig, Thomas Dillig, Boyang Li, and Kenneth L. McMillan. Inductive invariant generation via abductive inference. In *Proceedings of the 34th ACM SIGPLAN Conference on Programming Language Design and Implementation*, pages 443–456, 2013. doi: 10.1145/2491956.2462187.
- [19] Ran El-Yaniv and Yair Wiener. On the foundations of noise-free selective classification. *Journal of Machine Learning Research*, 11:1605–1641, 2010.
- [20] Bernd Finkbeiner, Markus N. Rabe, and César Sánchez. Model checking hyperltl. In *Computer Aided Verification*, volume 9206 of *Lecture Notes in Computer Science*, pages 30–48, 2015. doi: 10.1007/978-3-319-21690-4_3.
- [21] Luyu Gao, Aman Madaan, Shuyan Zhou, Uri Alon, Pengfei Liu, Yiming Yang, Jamie Callan, and Graham Neubig. Pal: Program-aided language models. In *International Conference on Machine Learning*, 2023.
- [22] Yonatan Geifman and Ran El-Yaniv. Selective classification for deep neural networks. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [23] Yonatan Geifman and Ran El-Yaniv. SelectiveNet: A deep neural network with an integrated reject option. In *International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 2151–2159, 2019.
- [24] Zhibin Gou, Zhihong Shao, Yeyun Gong, Yelong Shen, Yujiu Yang, Nan Duan, and Weizhu Chen. CRITIC: Large language models can self-correct with tool-interactive critiquing. In *International Conference on Learning Representations*, 2024.
- [25] Zhibin Gou, Zhihong Shao, Yeyun Gong, Yelong Shen, Yujiu Yang, Minlie Huang, Nan Duan, and Weizhu Chen. ToRA: A tool-integrated reasoning agent for mathematical problem solving. In *International Conference on Learning Representations*, 2024.

- [26] Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. Measuring mathematical problem solving with the MATH dataset. In *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks*, volume 1, 2021.
- [27] Jie Huang, Xinyun Chen, Swaroop Mishra, Huaixiu Steven Zheng, Adams Wei Yu, Xinying Song, and Denny Zhou. Large language models cannot self-correct reasoning yet. In *International Conference on Learning Representations*, 2024.
- [28] Albert Qiaochu Jiang, Sean Welleck, Jin Peng Zhou, Wenda Li, Jiacheng Liu, Mateja Jamnik, Timothée Lacroix, Yuhuai Wu, and Guillaume Lample. Draft, sketch, and prove: Guiding formal theorem provers with informal proofs. In *International Conference on Learning Representations*, 2023.
- [29] Albert Qiaochu Jiang, Wenda Li, and Mateja Jamnik. Multilingual mathematical autoformalization. In *International Conference on Learning Representations*, 2024.
- [30] Saurav Kadavath, Tom Conerly, Amanda Askell, Tom Henighan, Dawn Drain, Ethan Perez, Nicholas Schiefer, Zac Hatfield-Dodds, Nova DasSarma, Eli Tran-Johnson, Scott Johnston, Sheer El-Showk, Andy Jones, Nelson Elhage, Tristan Hume, Anna Chen, Yuntao Bai, Sam Bowman, Stanislav Fort, Deep Ganguli, Danny Hernandez, Josh Jacobson, Jackson Kernion, Shauna Kravec, Liane Lovitt, Kamal Ndousse, Catherine Olsson, Sam Ringer, Dario Amodei, Tom Brown, Jack Clark, Nicholas Joseph, Ben Mann, Sam McCandlish, and Jared Kaplan. Language models (mostly) know what they know. *arXiv preprint arXiv:2207.05221*, 2022.
- [31] Lorenz Kuhn, Yarin Gal, and Sebastian Farquhar. Semantic uncertainty: Linguistic invariances for uncertainty estimation in natural language generation. In *International Conference on Learning Representations*, 2023.
- [32] Junbo Jacob Lian, Yujun Sun, Huiling Chen, Chaoyu Zhang, Hanzhang Qin, and Chung-Piaw Teo. Reloop: Structured modeling and behavioral verification for reliable llm-based optimization. *arXiv preprint arXiv:2602.15983*, 2026.
- [33] Mark H. Liffiton and Karem A. Sakallah. Algorithms for computing minimal unsatisfiable subsets of constraints. *Journal of Automated Reasoning*, 40:1–33, 2008. doi: 10.1007/s10817-007-9084-z.
- [34] Hunter Lightman, Vineet Kosaraju, Yura Burda, Harrison Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s verify step by step. *arXiv preprint arXiv:2305.20050*, 2023.
- [35] Qing Lyu, Shreya Havaldar, Adam Stein, Li Zhang, Delip Rao, Eric Wong, Marianna Apidianaki, and Chris Callison-Burch. Faithful chain-of-thought reasoning. In *Proceedings of the 13th International Joint Conference on Natural Language Processing and the 3rd Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics*, pages 305–329, 2023. doi: 10.18653/v1/2023.ijcnlp-main.20.
- [36] Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegrefe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, Shashank Gupta, Bodhisattwa Prasad Majumder, Katherine Hermann, Sean Welleck, Amir Yazdanbakhsh, and Peter Clark. Self-refine: Iterative refinement with self-feedback. In *Advances in Neural Information Processing Systems*, volume 36, 2023.
- [37] Hussein Mozannar and David Sontag. Consistent estimators for learning to defer to an expert. In *International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 7076–7087, 2020.
- [38] Raymond Reiter. A theory of diagnosis from first principles. *Artificial Intelligence*, 32(1):57–95, 1987. doi: 10.1016/0004-3702(87)90062-2.
- [39] Dipankar Sarkar. From errors to proofs: Minimal-core-guided repair for neuro-symbolic constraint solving. *arXiv preprint arXiv:2608.14771*, 2026.
- [40] Timo Schick, Jane Dwivedi-Yu, Roberto Dessì, Roberta Raileanu, Maria Lomeli, Luke Zettlemoyer, Nicola Cancedda, and Thomas Scialom. Toolformer: Language models can teach themselves to use tools. In *Advances in Neural Information Processing Systems*, volume 36, 2023.

- [41] Armando Solar-Lezama, Liviu Tancau, Rastislav Bodik, Sanjit A. Seshia, and Vijay A. Saraswat. Combinatorial sketching for finite programs. In *Proceedings of the 12th International Conference on Architectural Support for Programming Languages and Operating Systems*, pages 404–415, 2006. doi: 10.1145/1168857.1168907.
- [42] Marcelo Sousa and Isil Dillig. Cartesian hoare logic for verifying k -safety properties. In *Proceedings of the 37th ACM SIGPLAN Conference on Programming Language Design and Implementation*, pages 57–69, 2016. doi: 10.1145/2908080.2908092.
- [43] Tachio Terauchi and Alex Aiken. Secure information flow as a safety problem. In *Static Analysis*, volume 3672 of *Lecture Notes in Computer Science*, pages 352–367, 2005.
- [44] Jonathan Uesato, Nate Kushman, Ramana Kumar, Francis Song, Noah Siegel, Lisa Wang, Antonia Creswell, Geoffrey Irving, and Irina Higgins. Solving math word problems with process- and outcome-based feedback. *arXiv preprint arXiv:2211.14275*, 2022.
- [45] Shyam Upadhyay and Ming-Wei Chang. Annotating derivations: A new evaluation strategy and dataset for algebra word problems. In *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 1, Long Papers*, pages 494–504. Association for Computational Linguistics, 2017. URL <https://aclanthology.org/E17-1047/>.
- [46] Ke Wang, Houxing Ren, Aojun Zhou, Zimu Lu, Sichun Luo, Weikang Shi, Renrui Zhang, Linqi Song, Mingjie Zhan, and Hongsheng Li. Mathcoder: Seamless code integration in LLMs for enhanced mathematical reasoning. In *International Conference on Learning Representations*, 2024.
- [47] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc V. Le, and Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models. In *Advances in Neural Information Processing Systems*, 2022.
- [48] Yixuan Weng, Minjun Zhu, Shizhu He, Kang Liu, and Jun Zhao. Large language models are better reasoners with self-verification. *Findings of the Association for Computational Linguistics: EMNLP 2023*, 2023.
- [49] Yuhuai Wu, Albert Qiaochu Jiang, Wenda Li, Markus N. Rabe, Charles Staats, Mateja Jamnik, and Christian Szegedy. Autoformalization with large language models. In *Advances in Neural Information Processing Systems*, volume 35, 2022.
- [50] Huajian Xin, Daya Guo, Zhihong Shao, Zhizhou Ren, Qihao Zhu, Bo Liu, Chong Ruan, Wenda Li, and Xiaodan Liang. Deepseek-prover: Advancing theorem proving in LLMs through large-scale synthetic data. *arXiv preprint arXiv:2405.14333*, 2024.
- [51] Kaiyu Yang, Aidan M. Swope, Alex Gu, Rahul Chalamala, Peiyang Song, Shixing Yu, Saad Godil, Ryan Prenger, and Anima Anandkumar. Leandojo: Theorem proving with retrieval-augmented language models. In *Advances in Neural Information Processing Systems*, volume 36, 2023.
- [52] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. ReAct: Synergizing reasoning and acting in language models. In *International Conference on Learning Representations*, 2023.
- [53] Huaiyuan Ying, Zijian Wu, Yihan Geng, Jiayu Wang, Dahua Lin, and Kai Chen. Lean workbook: A large-scale lean problem set formalized from natural language math problems. In *Advances in Neural Information Processing Systems Datasets and Benchmarks Track*, 2024.
- [54] Zhouliang Yu, Ruotian Peng, Keyi Ding, Yizhe Li, Zhongyuan Peng, Minghao Liu, Yifan Zhang, Zheng Yuan, Huajian Xin, Wenhao Huang, Yandong Wen, Ge Zhang, and Weiyang Liu. Formalmath: Benchmarking formal mathematical reasoning of large language models. *arXiv preprint arXiv:2505.02735*, 2025.
- [55] Kunhao Zheng, Jesse Michael Han, and Stanislas Polu. minif2f: A cross-system benchmark for formal olympiad-level mathematics. In *International Conference on Learning Representations*, 2022.